Trading on Attention: Os Pageviews da Wikipedia Preveem Retornos Diários de Ações? Um Teste Walk-Forward com Dados de 2016–2019

Lucas de Morais Ruga
Insper Instituto de Ensino e Pesquisa, São Paulo, Brasil
Projeto independente de portfólio, a partir de um case do AI for Business & Finance Certificate
(Columbia Business School Executive Education × Wall Street Prep)

Status: modelo e plano de análise definidos antes de rodar o período de teste; resultados a serem adicionados.

Problema

A Wikipedia registra quantas vezes cada artigo é lido por dia. Para uma empresa listada, esses pageviews são uma medida gratuita e diária de quanta atenção a empresa recebe. A pergunta por trás deste projeto é se essa atenção contém informação sobre o retorno da ação nos dias seguintes.

O projeto parte do case "Trading with AI" do AI for Business & Finance Certificate. O case usa os pageviews diários da Wikipedia de 50 grandes ações do S&P 500 para prever o retorno do dia seguinte, monta uma carteira a partir das previsões e a compara com o S&P 500 (SPY) ao longo de 2017. Um único ano de teste é uma base estreita para uma conclusão: 2017 foi um ano de alta forte e baixa volatilidade, e a comparação usa o SPY como único benchmark.

Este projeto reimplementa o case com dados baixados de forma independente, mantém o modelo inalterado e estende o estudo para janeiro de 2016 a dezembro de 2019, com três anos de teste e uma avaliação mais rigorosa. A pergunta de pesquisa é:

> *Pergunta de pesquisa: Os pageviews defasados da Wikipedia melhoram as previsões out-of-sample do retorno do dia seguinte de grandes ações americanas além dos retornos defasados, e uma carteira construída a partir dessas previsões se sustenta diante de benchmarks justos, custos de transação e seleção aleatória de ações?*

Descrição do Modelo e Métodos

Visão geral

O modelo é uma estratégia de ranking de ações. Para cada ação, uma regressão linear própria prevê o retorno do dia a partir da semana anterior. Todo dia de pregão, as 50 previsões são ordenadas e a carteira fica com as dez ações de maior retorno previsto. Três modelos aninhados acrescentam informação de atenção passo a passo, o que permite isolar a contribuição dos pageviews (Figura 1). Os modelos são reestimados todo mês usando apenas dados passados.

Especificação do modelo

Universo e dados. O universo é formado por 50 grandes ações do S&P 500 e, para cada uma, quatro concorrentes, conforme definido no case original, em que a lista foi gerada com o ChatGPT. Os preços diários das 50 ações e do SPY são baixados com o `yfinance`, e os pageviews diários do artigo de cada empresa na Wikipedia em inglês vêm da Wikimedia Pageviews API; os redirects de artigos (por exemplo, "The Home Depot" → "Home Depot") são resolvidos pela API da Wikipedia. Dados posteriores a 2019 são excluídos para deixar a pandemia de COVID-19 fora da amostra.

Variáveis. O retorno diário da ação i é

$$r_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}}.$$

A atenção entra de duas formas: os pageviews brutos $v_{i,t}$ e as views proporcionais, isto é, a participação da ação nas views do seu grupo de concorrentes C_i (a própria ação e seus quatro concorrentes),

$$s_{i,t} = \frac{v_{i,t}}{\sum_{j \in C_i} v_{j,t}}.$$

Cada preditor é uma média de sete dias defasada em um dia, de modo que o dia t usa apenas informação até $t-1$:

$$\bar{x}_{i,t} = \tfrac{1}{7} \textstyle\sum_{k=1}^{7} x_{i,t-k}, \quad x \in \{r, v, s\}.$$

Modelos de previsão. Para cada ação, são estimados três modelos por OLS:

$$\begin{aligned}
\text{M1:}\ & r_{i,t} = \alpha + \beta_1 \bar{r}_{i,t} + \varepsilon_{i,t} \\
\text{M2:}\ & r_{i,t} = \alpha + \beta_1 \bar{r}_{i,t} + \beta_2 \bar{v}_{i,t} + \varepsilon_{i,t} \\
\text{M3:}\ & r_{i,t} = \alpha + \beta_1 \bar{r}_{i,t} + \beta_2 \bar{v}_{i,t} + \beta_3 \bar{s}_{i,t} + \varepsilon_{i,t}
\end{aligned}$$

O M1 usa apenas retornos passados; o M2 e o M3 testam se a atenção acrescenta informação a ele.

Regra de trading. Em cada dia de teste t, o modelo m gera um retorno previsto $\hat{r}^m_{i,t}$ para as 50 ações. A carteira fica com as dez primeiras, com pesos iguais, por um dia, o que dá o retorno da estratégia

$$R^m_t = \tfrac{1}{10} \textstyle\sum_{i \in \mathrm{Top}_{10}(\hat{r}^m_{\cdot,t})} r_{i,t}.$$

A estratégia é long-only e rebalanceada todo dia.

Desenho walk-forward. A amostra vai de janeiro de 2016 a dezembro de 2019. Os pageviews existem desde julho de 2015, mas a amostra começa em 2016 porque a janela de treino é de 12 meses: um ano completo (janeiro a dezembro de 2016) forma a primeira janela de treino, como no case

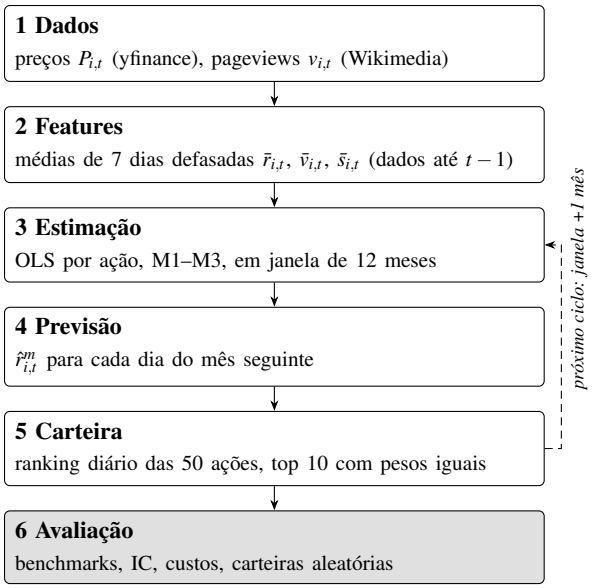


Figura 1: Pipeline de um ciclo walk-forward. As etapas 3–5 se repetem em cada um dos 36 ciclos mensais; a etapa 6 é aplicada uma vez a todo o período de teste, 2017–2019.

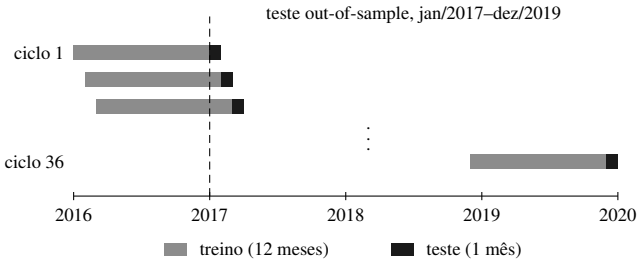


Figura 2: Desenho walk-forward. Cada ciclo treina em 12 meses e testa no mês seguinte; a janela avança um mês por vez.

original, e o segundo semestre de 2015 não formaria uma janela completa. Apenas os últimos dias de dezembro de 2015 são usados, para calcular as médias defasadas de sete dias da primeira semana de janeiro de 2016. A estimação segue um esquema walk-forward rolling (Figura 2). Cada ciclo estima os modelos numa janela de 12 meses e prevê o mês seguinte; depois, a janela avança um mês. A primeira janela cobre janeiro a dezembro de 2016 e prevê janeiro de 2017; a última cobre dezembro de 2018 a novembro de 2019 e prevê dezembro de 2019, o que dá 36 ciclos mensais e três anos de teste out-of-sample. Os 12 primeiros ciclos correspondem ao teste de 2017 do case original e, por isso, validam a reimplementação.

Medidas.

(1) retorno acumulado e anual, volatilidade, Sharpe ratio, maximum drawdown e hit rate de cada estratégia;

(2) comparação com dois benchmarks: SPY e uma carteira equal-weight das 50 ações;

(3) information coefficient (IC): a correlação de Spearman diária entre retornos previstos e realizados nas 50 ações, e sua média no período de teste;

(4) estabilidade de β_2 e β_3 ao longo dos 36 ciclos, com intervalos de confiança;

(5) turnover diário e retorno acumulado com 0, 5, 10 e 20 bps de custos de transação;

(6) posição do retorno de cada estratégia na distribuição de milhares de carteiras aleatórias de dez ações do mesmo universo;

(7) resultados apresentados separadamente para 2017, 2018 e 2019.

Justificativa das Escolhas

O modelo é mantido idêntico ao do case original de propósito. O objetivo é testar se o resultado do case se sustenta, não encontrar um sinal melhor. Mudar features, tamanho das janelas ou tamanho da carteira depois de olhar o período de teste faria os resultados deixarem de ser out-of-sample. Por isso, todas as extensões estão na avaliação, não no modelo.

Os dados são divididos em ordem temporal, e não de forma aleatória. Como o próprio case mostra, uma divisão aleatória coloca dias posteriores no treino para prever dias anteriores, o que significa usar o futuro. A reestimação mensal mantém os coeficientes atualizados, em vez de operar no fim de 2019 com um modelo estimado com dados de 2016. O período 2017–2019 cobre três anos diferentes: alta forte e tranquila em 2017, queda acentuada no quarto trimestre de 2018 e recuperação em 2019, deixando a pandemia de fora.

O SPY sozinho não é um benchmark justo. Escolher dez ações de uma lista fixa de 50 grandes empresas mistura o efeito da lista com o efeito do sinal; uma carteira equal-weight das mesmas 50 ações separa os dois. O IC mede o poder preditivo diretamente, independentemente de como a carteira é montada. Rebalancear dez posições todo dia tem custo, por isso os resultados são mostrados com vários níveis de custo. As carteiras aleatórias mostram se o retorno da estratégia poderia ter vindo do acaso.

Plano de Análise

A análise segue três etapas. Primeiro, a reimplementação é verificada comparando os resultados de 2017 dos 12 primeiros ciclos com o case original. Segundo, o teste completo de 36 ciclos é rodado com todas as escolhas da Tabela 1 definidas de antemão. Terceiro, as medidas (1)–(7) são calculadas e apresentadas num gráfico de retorno acumulado contra os dois benchmarks, numa tabela de performance, num gráfico de retornos por ano, num gráfico do IC, num gráfico dos coeficientes ao longo dos ciclos, num gráfico de custos de transação e num histograma das carteiras aleatórias.

Tabela 1: Parâmetros do modelo, valores e justificativa.

Parâmetro	Símbolo	Valor	Justificativa
Universo	N	50 ações	Case original
Grupo de concorrentes	C_i	ação + 4 concorrentes	Case original; define as views proporcionais $s_{i,t}$
Período dos dados	–	jan/2016–dez/2019	Começa com a primeira janela de treino completa de 12 meses; 2020 em diante excluído (COVID-19)
Janela das features	–	7 dias, defasagem de 1 dia	Case original; usa apenas dados até $t-1$
Janela de treino	–	12 meses, rolling	Case original; mantém os coeficientes atualizados
Janela de teste	–	1 mês	Case original; reestimação mensal
Primeira janela de treino	–	jan–dez/2016	12 meses, como no case original
Período de teste	–	jan/2017–dez/2019	Três anos out-of-sample
Ciclos	–	36	Os 12 primeiros reproduzem o case
Estimador	–	OLS por ação	Case original; modelos aninhados M1–M3
Tamanho da carteira	K	10, pesos iguais	Case original
Holding period	–	1 dia	Case original; rebalanceamento diário
Benchmarks	–	SPY; equal-weight 50	Mercado e o mesmo universo de 50 ações
Custos de transação	c	0, 5, 10, 20 bps	Sensibilidade dos resultados aos custos
Carteiras aleatórias	–	milhares	Referência de acaso para escolher 10 de 50